

Modelo Chen autorregressivo e de médias móveis bidimensional: Uma alternativa para modelagem e detecção de anomalias em imagens SAR

Renata Figueiredo Stone¹ Laís Helen Loose² Renata Rojas Guerra³
Fábio M. Bayer⁴

¹UFSM; renata.stone@acad.ufsm.br ²UFSM; lais.loose@ufsm.br
³UFSM; renata.r.guerra@ufsm.br ⁴UFSM; bayer@ufsm.br

Introdução

Escolher adequadamente a distribuição para modelar um conjunto de dados é fundamental na análise estatística. No contexto de imagens digitais, imagens de sensoriamento remoto são uma das ferramentas mais importantes para o monitoramento do ambiente físico. Um exemplo seriam as imagens de radar de abertura sintética (SAR) que destacam-se por sua característica de insensibilidade à presença de nuvens e de captura durante o dia ou à noite.

Para a modelagem e predição dessas imagens digitais é conhecido na literatura o modelo autorregressivo e de médias móveis bidimensional assumindo a distribuição Rayleigh, o modelo 2-D RARMA [1]. Uma alternativa para essa distribuição, seria a distribuição Chen [2]. O que as diferencia é o fato da distribuição Chen ser biparamétrica e, por consequência, mais flexível, pois seus parâmetros de forma possibilitam um melhor ajuste da assimetria e amplitude. Outra diferença é a reparametrização da função densidade de probabilidade da Chen através da mediana. O uso da mediana é apropriado quando a variável de interesse apresenta comportamentos assimétricos, pois tende a ser uma medida mais robusta e menos influenciada por outliers do que a média. Sendo assim, é esperado que um modelo mais flexível e robusto apresentará um desempenho superior na modelagem de imagens digitais não homogêneas como, por exemplo, imagens SAR de regiões urbanas.

O modelo Chen autorregressivo e de médias móveis (CHARMA) [3] foi recentemente proposto para modelagem de dados assimétricos, contínuos e positivos observados ao longo do tempo, com base na distribuição Chen. Com o objetivo de estender esse modelo e agregar modelos bidimensionais à literatura, no presente trabalho é proposto o modelo CHARMA bidimensional (2-D CHARMA) para modelagem de imagens espacialmente autocorrelacionadas não Gaussianas, em que o sinal observado é assimétrico e estritamente positivo.

A Distribuição Chen Reparametrizada

O modelo dinâmico bidimensional assumindo a distribuição Chen será proposto utilizando uma reparametrização da distribuição Chen pela mediana, a qual foi introduzida por [3].

A densidade reparametrizada em termos da mediana (μ) é dada por [3]

$$f(y; \lambda, \mu) = \frac{\log(0.5)}{1 - \exp(\mu^\lambda)} \lambda y^{\lambda-1} \exp \left\{ \frac{\log(0.5)}{[1 - \exp(\mu^\lambda)]} [1 - \exp(y^\lambda)] + y^\lambda \right\}. \quad (1)$$

A função de distribuição acumulada da distribuição Chen reparametrizada é dada por

$$F(y; \lambda, \mu) = 1 - \exp \left\{ \frac{\log(0.5)}{1 - \exp(\mu^\lambda)} [1 - \exp(y^\lambda)] \right\}, \quad y > 0.$$

Para ilustrar as diferentes formas que a distribuição Chen reparametrizada pode assumir, apresentamos na Figura 1 as formas da função densidade considerando diferentes valores para λ e μ .




Figura 1: Função densidade de probabilidade do modelo reparametrizado, considerando diferentes valores para λ e μ .

Modelo CHARMA Bidimensional

O modelo 2-D CHARMA é proposto como uma extensão espacial do modelo CHARMA unidimensional. Sendo assim, considere que $Y[n, m]$, com $n = 1, 2, \dots, N$, $m = 1, 2, \dots, M$, é uma variável aleatória que representa os pixels de uma imagem com dimensão $N \times M$. O modelo 2-D CHARMA parte do princípio de que cada pixel $Y[n, m]$ possui, condicional a alguma vizinhança, $S[n, m] = \{[k, l] \in \mathbb{Z} : 1 < k < n, 1 < l < m\} - \{[n, m]\}$, distribuição Chen, com densidade dada na Equação (1).

Sendo assim, o modelo proposto pode ser definido como

$$\Phi(z_1, z_2)g(y[n, m]) = \beta + \Theta(z_1, z_2)\varepsilon[n, m],$$

em que $\beta \in \mathbb{R}$ é o intercepto do modelo, $y[n, m]$ é uma ocorrência do sinal $Y[n, m]$ e $g(\cdot)$ é uma função de ligação duas vezes diferenciável, em que, $g: \mathbb{R}^+ \rightarrow \mathbb{R}$. Os polinômios $\Phi(z_1, z_2)$ e $\Theta(z_1, z_2)$ representam, respectivamente,

$$\Phi(z_1, z_2) = 1 - \sum_{i=0}^p \sum_{j=0}^p \phi_{(i,j)} z_1^{-i} z_2^{-j},$$

$$\Theta(z_1, z_2) = 1 + \sum_{k=0}^q \sum_{l=0}^q \theta_{(k,l)} z_1^{-k} z_2^{-l},$$

os parâmetros autorregressivos e de médias móveis respectivamente são $\phi_{(i,j)}$ e $\theta_{(k,l)}$, com $i, j = 0, 1, \dots, p$ e $k, l = 0, 1, \dots, q$. Note que p e q são as ordens do modelo 2-D CHARMA(p, q), z_1^{-i} atua como o operador para o retrocesso nas linhas, enquanto z_2^{-j} é o operador para o retrocesso nas colunas. Sendo assim, a operação relacionada ao componente autorregressivo é definida como $z_1^{-i}g(y[n, m]) = g(y[n - i, m])$, e $z_2^{-j}g(y[n, m]) = g(y[n, m - j])$. Os operadores para os erros de médias móveis são expressos como $z_1^{-k}e[n, m] = e[n - k, m]$ e $z_2^{-l}e[n, m] = e[n, m - l]$.

Substituindo os componentes indicados acima, o modelo 2-D CHARMA(p, q) irá representar a mediana de $Y[n, m]$ por meio da seguinte estrutura

$$g(\mu[n, m]) = \beta + \sum_{i=0}^p \sum_{j=0}^p \phi_{(i,j)} g(y[n - i, m - j]) + \sum_{k=0}^q \sum_{l=0}^q \theta_{(k,l)} \varepsilon[n - k, m - l],$$

em que o termo de erro é $\varepsilon[n, m] = g(y[n, m]) - g(\mu[n, m])$ e $g(\mu[n, m]) = \eta[n, m]$ o preditor linear. A Figura 2 ilustra a relação espacial no modelo bidimensional proposto.




Figura 2: Relação espacial da vizinhança em modelos bidimensionais, por exemplo 2-D CHARMA(1,1).

Considere que $\gamma = (\beta, \phi^\top, \theta^\top, \lambda)^\top$ é o vetor de parâmetros desconhecidos, em que $\phi = (\phi_{(0,1)}, \phi_{(0,2)}, \dots, \phi_{(p,p)})^\top$ e $\theta = (\theta_{(0,1)}, \theta_{(0,2)}, \dots, \theta_{(q,q)})^\top$, com dimensões $(p+1)^2 - 1$ e $(q+1)^2 - 1$, respectivamente. Considerando $w = \max(p, q)$, a estimação dos parâmetros baseada na amostra pode ser realizada maximizando a função de log-verossimilhança condicional através da expressão:

$$\ell(\gamma) = \sum_{n=w+1}^N \sum_{m=w+1}^M \ell[n, m](\mu[n, m], \lambda),$$

em que

$$\ell[n, m](\mu[n, m], \lambda) = \log \left[\frac{\log(0.5)}{1 - \exp(\mu[n, m]^\lambda)} \right] + (\lambda - 1) \log(y[n, m]) + \log(\lambda) + \frac{\log(0.5) [1 - \exp(y[n, m]^\lambda)]}{1 - \exp(\mu[n, m]^\lambda)} + y[n, m]^\lambda.$$

Os estimadores de máxima verossimilhança condicional (EMVC), $\hat{\gamma} = (\hat{\beta}, \hat{\phi}^\top, \hat{\theta}^\top, \hat{\lambda})^\top$ do vetor de parâmetros γ , são obtidos pela maximização da função de log-verossimilhança condicional. Para isso, é necessário solucionar o sistema de equações a seguir:

$$\mathbf{U}(\gamma) = \frac{\partial \ell}{\partial \gamma} = \left(\frac{\partial \ell}{\partial \beta}, \frac{\partial \ell}{\partial \phi^\top}, \frac{\partial \ell}{\partial \theta^\top}, \frac{\partial \ell}{\partial \lambda} \right)^\top = \mathbf{0}, \quad (2)$$

em que $\mathbf{0}$ é um vetor com $(p+1)^2 + (q+1)^2$ zeros.

No presente trabalho utilizamos o método de otimização numérica Broyden-Fletcher-Goldfarb-Shanno (BFGS) da função *optim* disponível em linguagem R para solucionar o sistema indicado na equação (2).

Avaliação Numérica dos Estimadores

Para avaliar as propriedades dos estimadores de máxima verossimilhança do modelo proposto foram utilizadas simulações de Monte Carlo. A implementação computacional foi desenvolvida em linguagem R. O número de réplicas de Monte Carlo foi fixado em 500. Considerou-se diferentes tamanhos de imagens simuladas, $N \times M \in \{10 \times 10, 25 \times 25, 50 \times 50\}$. Os resultados da média, viés, viés relativo percentual (VR%), erro-padrão (EP) e o erro quadrático médio (EQM) são apresentados na Tabela 1.

Tabela 1: Resultados da simulação de Monte Carlo para avaliação dos EMVCs dos parâmetros do modelo 2-D CHARMA(1,1), considerando o cenário: $\beta = 0.6$, $\phi_{0,1} = 0.26$, $\phi_{1,0} = 0.28$, $\phi_{1,1} = 0.25$, $\theta_{0,1} = 0.15$, $\theta_{1,0} = 0.17$, $\theta_{1,1} = 0.14$ e $\lambda = 0.86$.

$N \times M$	Métricas	$\hat{\beta}$	$\hat{\phi}_{0,1}$	$\hat{\phi}_{1,0}$	$\hat{\phi}_{1,1}$	$\hat{\theta}_{0,1}$	$\hat{\theta}_{1,0}$	$\hat{\theta}_{1,1}$	$\hat{\lambda}$
10	Média	0.6004	0.2580	0.2824	0.2469	0.1469	0.1625	0.1325	0.8741
	VR%	0.0735	-0.7723	0.8494	-1.2582	-2.0746	-4.4180	-5.3879	1.6351
	DP	0.1730	0.1170	0.1121	0.1508	0.1481	0.1472	0.1469	0.0327
	EQM	0.0299	0.0137	0.0126	0.0228	0.0219	0.0217	0.0216	0.0013
	Média	0.5995	0.2596	0.2832	0.2457	0.1480	0.1635	0.1356	0.8674
25	VR%	-0.0755	-0.1480	1.1518	-1.7086	-1.3191	-3.7977	-3.1312	0.8622
	DP	0.1303	0.0868	0.0831	0.1119	0.1087	0.1080	0.1075	0.0251
	EQM	0.0170	0.0075	0.0069	0.0125	0.0118	0.0117	0.0116	0.0007
	Média	0.5997	0.2598	0.2825	0.2467	0.1485	0.1652	0.1364	0.8648
	VR%	-0.0556	-0.0639	0.8880	-1.3266	-1.0153	-2.8405	-2.5634	0.5629
50	DP	0.1083	0.0719	0.0688	0.0927	0.0897	0.0891	0.0885	0.0210
	EQM	0.0117	0.0052	0.0047	0.0086	0.0081	0.0080	0.0079	0.0005

Aplicação em Imagem SAR

A fim de ilustrar a aplicabilidade do modelo proposto na modelagem de imagens SAR utilizamos a imagem da Baía de São Francisco, proveniente do sensor AIRSAR de banda L, com 200×350 e polarização HH.




Figura 3: Imagem da Baía de São Francisco (a) e a região selecionada (b) para fins de ajuste no modelo.

Tabela 2: Valores de erro percentual absoluto médio (MAPE%), EQM, log-verossimilhança maximizada (Loglik) e o critério de informação de Akaike (AIC) correspondentes aos cenários ajustados.

Cenário	MAPE%	EQM	Loglik	AIC
2-D CHARMA(1,0)	66.600	0.221	3045.931	-6081.861
2-D CHARMA(0,1)	107.200	0.335	2019.849	-4029.698
2-D CHARMA(1,1)	66.679	0.220	3047.904	-6079.808




Figura 4: Região ajustada pelos modelos 2-D CHARMA(1,0) (a) 2-D CHARMA(1,0) (b) e 2-D CHARMA(1,1) (c).

Conclusões

- Propomos um modelo para modelagem de dados com dependência espacial com base na distribuição Chen, o modelo 2-D CHARMA.
- Os resultados das simulações indicaram que os EMVCs possuem boas propriedades. Nas diferentes dimensões de imagens observamos evidências de que os estimadores são assintoticamente não viesados e consistentes.
- Para trabalhos futuros serão exploradas aplicações voltadas à detecção de anomalias em imagens SAR. Além disso, a implementação e a disponibilização de um pacote em linguagem R para ajuste do modelo 2-D CHARMA será desenvolvido.

Referências

- [1] Palm, B. G., Bayer, F. M., Cintra, R. J., 2022. 2-D Rayleigh autoregressive moving average model for SAR image modeling. Computational Statistics & Data Analysis 171, 107453.
- [2] Chen, Z., 2000. A new two-parameter lifetime distribution with bathtub shape or increasing failure rate function. Statistics & Probability Letters 49 (2), 155–161.
- [3] Stone, R. F., Loose, L. H., Melo, M. S., Bayer, F. M., 2023. The Chen Autoregressive Moving Average Model for Modeling Asymmetric Positive Continuous Time Series. Symmetry 15 (9), 1675.

Agradecimentos